

PPO ve SAC Karşılaştırması

Çok-Odalı Drone Keşfinde On-policy vs Off-policy — Yan-Yana Grafik Kıyası

Berker Yiğit – 220202046 | Algoritma sorumluluğu: PPO

SAC grafikleri: M. A. Albayrak (220202082) teslimi | Ortam birebir aynı (MD5 özdeş)

1 Neden Bu Karşılaştırma Adildir ve Nasıl Yapıldı?

Bu belge, PPO (on-policy) ile SAC (off-policy) ajanlarını **birebir aynı ortamda** karşılaştırır. Karşılaştırmanın geçerli olması için tek farkın algoritma olması gerekir:

- **Ortam birebir aynıdır:** `fast_2d_drone_env.py` iki teslimde de bayt-bayt özdeştir (MD5 61ec1d6a...). Durum uzayı $\text{Box}(75)$ (64 lidar, 5.625°), eylem uzayı $\text{Box}(-1, 1)^3$, ödül fonksiyonu, gürültü parametreleri, oda/kapı yerleşimi ve episode uzunluğu (600) aynıdır.
- **Tohumlar aynıdır:** her iki ajan da $\{7, 13, 42, 123, 2025\}$ ile eğitilmiştir.
- **Aynı protokol:** deterministik (greedy) eval; aynı metrikler.

Ekip arkadaşımız M. A. Albayrak SAC ile 200k+ birçok versiyon denediğinden, aynı işi tekrarlamak yerine onun *yayınlanmış* SAC grafiklerini (220202082 sunumundan) bizim aynı tip PPO grafiğimizin **yanına** koyduk. Her figürde *sol* panel PPO (bu çalışma), *sağ* panel SAC'tır.


Tablo 1: PPO ve SAC ortalama sonuçları (her sütun ilgili teslimin yayınlanmış değeri).

Ölçüt	PPO (bu çalışma)	SAC (M. A. Albayrak, 220202082)
Aile	on-policy	off-policy
Replay buffer	yok	var
Ort. getiri (5 tohum)	458.5	314.6
Ort. oda (/6)	5.80	4.83
Tam-keşif başarı oranı	0.96	0.34
En iyi tohum getirisi	474.6	393.7 (tohum 123)

PPO: deterministik eval, 5 tohum ortalaması. SAC: M. A. Albayrak'ın 220202082 teslimindeki yayınlanmış değerler (son 50 episode ort.). Ortam, durum/eylem uzayı ve protokol birebir aynıdır.


2 Yan-Yana Grafik Kıyasları

PPO ↔ SAC — Öğrenme Eğrisi (episode getirisi)




Öğrenme eğrisi. Her iki ajan da platoya oturur; PPO platosu (~480) SAC'ın seed-123 platosunun (~390) üzerinde ve daha dar bantlıdır (kararlı). SAC off-policy olduğu için daha az adımda yakınsar (örnek-verimli), PPO daha çok adımla daha yüksek nihai getiriye ulaşır.

PPO ↔ SAC — Tohum 123 Detay Paneli (getiri / eval / kapsama / oda)




Tohum 123 detay paneli. Dört panelde de (getiri / eval / kapsama / oda) PPO eğrileri daha yüksek ve daha az dalgalı; ikisi de coverage'ı %90+ ve oda sayısını 5-6'ya taşır. İki algoritma da görevi çözer; PPO daha yüksek tavanla.

PPO ↔ SAC — Baseline Karşılaştırma (görev metrikleri)




Baseline (görev metrikleri). Her iki ajan da rastgele ve sezgisel taban politikaları geçer; tam-keşif başarısında PPO (~%96) SAC'ın (~%60 en iyi, %34 ort.) belirgin önündedir.

PPO ↔ SAC — Hiperparametre Duyarlılığı



Hiperparametre duyarlılığı. İki algoritmada da orta hiperparametre değerleri en iyi sonucu verir (keşif-sömürü dengesi); sonuç ince ayara aşırı duyarlı değildir.

PPO ↔ SAC — Loss Eğrisi (actor & critic)




Loss eğrileri. PPO'da klips mekanizması güncellemeleri sıkı sınırlar (actor loss küçük/yatay); SAC'ta entropi düzenlemesi + replay ile loss daha geniş salınır. Her ikisi de kararlı yakınsama gösterir.

PPO ↔ SAC — $\gamma \times \text{learning_rate}$ Hiperparametre Arama

PPO — bu çalışma (Berker, 220202046)

10) Hiperparametre Arama -- $\gamma \times \text{learning_rate}$ ızgarası (3 seed)



SAC — M. A. Albayrak (220202082)

Hiperparametre Arama Sonuçları (Seed=42, 2000 adım)



$\gamma \times \text{lr}$ araması. Her iki algoritmada da en iyi bölge orta-yüksek γ + düşük-orta lr köşesidir; bu, ortamın paylaşılan yapısını (gecikmeli oda ödülü) yansıtır.

3 Sonuç

Aynı MDP üzerinde yapılan bu yan-yana karşılaştırma, iki algoritma ailesinin doğasını gösterir. SAC (off-policy, replay buffer'lı) örnek-verimlidir ve az adımda yakınsar; PPO (on-policy) daha çok örnek gerektirir ama bu çok-odalı keşif ortamında daha yüksek nihai görev başarısına (getiri, oda, tam-keşif) ulaşır. Ortam, durum/eylem uzayı, tohum ve protokol birebir aynı olduğundan, gözlenen fark yalnızca algoritmadan kaynaklanır.