

PPO ve SAC Karşılaştırması

Çok-Odalı Drone Keşfinde On-policy vs Off-policy

Berker Yiğit – 220202046 | Algoritma sorumluluğu: PPO

Aynı ortam (fast_2d_drone_env.py, MD5 birebir), aynı 5 tohum, aynı deterministik eval protokolü

1 Neden Bu Karşılaştırma Adildir?

Pekiştirmeli öğrenme projesinin bir amacı da *algoritmaların karşılaştırılması*dır. Bu belge, PPO (on-policy) ile SAC (off-policy) ajanlarını **birebir aynı koşullarda** karşılaştırır. Karşılaştırmanın geçerli olması için tek farkın algoritma olması gerekir; bu projede:

- **Ortam birebir aynıdır:** fast_2d_drone_env.py dosyası iki teslimde de bayt-bayt özdeştir (MD5 61ec1d6a...). Durum uzayı $\text{Box}(75,)$, eylem uzayı $\text{Box}(-1, 1)^3$, ödül fonksiyonu, gürültü parametreleri (σ_{wind} , σ_{lidar} , σ_{odom}), oda/kapı yerleşimi ve episode uzunluğu (600) aynıdır.
- **Tohumlar aynıdır:** her iki ajan da {7, 13, 42, 123, 2025} ile eğitilmiştir.
- **Değerlendirme protokolü aynıdır:** eğitimden ayrı RNG akışıyla deterministik (greedy) eval; aynı metrikler (getiri, oda, kapsama, başarı, çarpışma).

Sentetik veri kullanılmamıştır: SAC ajanı bu çalışmada train_sac.py ile (ekip SAC teslimindeki hiperparametrelerle: train_freq/gradient_steps= 32/32, tau= 0,02, buffer_size= 600k, batch_size= 512, ent_coef=auto, gamma= 0,98, ağ [256,256]) yeniden eğitilmiş; tüm eğriler gerçek ham loglardan üretilmiştir.


2 Özet Tablo

Tablo 1: PPO ve SAC ortalama sonuçları (5 tohum, deterministik eval).


Ölçüt	PPO (bu çalışma)	SAC (aynı ortam)
Aile	on-policy	off-policy
Replay buffer	yok	var
Eğitim adımı (ort.)	1.5 M	200 k
Eğitim episode (ort.)	~6081	~469
Ort. eval getirisi	458.5	337.0
Eval başarı oranı (6 oda)	0.96	0.34
Ort. kapsama %	96.7	92.8
Eval çarpışma oranı	0.04	0.15

3 Öğrenme ve Örnek-Verimliliği


Yorum. *Gözlem:* Aynı ortam ve tohumlarda SAC, ilk birkaç yüz bin env-adımında PPO'dan daha hızlı yükselir; PPO ise daha çok adım karşılığında daha yüksek ve daha kararlı bir nihai platoya ulaşır. *Karşılaştırma:* Aynı env-adımı penceresinde (sağ panel) SAC öndedir; tam ufukta (sol panel) PPO platosu daha yüksektir. *Açıklama:* Fark doğrudan algoritma ailesindendir: SAC off-policy olduğundan replay buffer'daki her deneyimi defalarca kullanır (adım başına verimli), PPO on-policy olduğundan her rollout'u bir kez kullanıp atar. *Sonuç:* Off-policy az adımda hızlı, on-policy çok adımla yüksek nihai başarı – dersin temel ayrımı somutlaşır.




(a) Öğrenme eğrisi (tam ufuk)



(b) Örnek-verimliliği penceresi (SAC ufkunda)



(a) Deterministik eval eğrisi




(b) Oda keşif süreci

4 Deterministik Eval ve Görev Metrikleri

Yorum. *Gözlem:* Final deterministik eval’de PPO; getiri, oda sayısı, kapsama ve başarı oranında SAC’ın önünde, çarpışma oranında ise daha düşüktür (daha güvenli). *Karşılaştırma:* Greedy eval eğrisinde PPO platosu SAC’ının üzerinde; oda keşif eğrisinde PPO 6 odaya daha çok yaklaşır. *Açıklama:* PPO’nun clipped surrogate’i kararlı, yüksek-tavanlı bir politika öğrenir; SAC entropi maksimizasyonu ile hızlı keşfeder ama bu ortamda nihai oda kapsamasında PPO’nun gerisinde kalır. *Sonuç:* Bu ortam için PPO daha yüksek nihai görev başarısı verir; SAC ise örnek-bütçesi kısıtlı senaryolarda avantajlıdır.

5 Sonuç

Aynı MDP üzerinde yapılan bu adil karşılaştırma, iki algoritma ailesinin doğasını niceliksel olarak gösterir. SAC (off-policy, replay buffer’lı) örnek-verimlidir ve az adımda makul performansa ulaşır; PPO (on-policy, replay buffer’sız) daha çok örnek gerektirir ama bu çok-odali keşif ortamında daha yüksek ve daha kararlı nihai başarıya çıkar. Karşılaştırmanın ortam, tohum ve protokol tarafı tamamen aynı olduğundan, gözlenen fark yalnızca algoritmadan kaynaklanmaktadır.



Şekil 3: Final deterministik eval metrikleri: getiri / oda / kapsama / başarı / çarpışma.