

Kapalı Ortamda PPO ile Lidar Tabanlı Drone Keşfi

Pekiştirmeli Öğrenme Dönem Projesi – Teknik Rapor

Berker Yiğit – 220202046

Kocaeli Üniversitesi, Bilgisayar Mühendisliği (II. Öğretim)

Algoritma: PPO (Proximal Policy Optimization) | Branch: algo/ppo

Depo: https://github.com/berkeryigit/rl_drone_pathfinding/tree/algo/ppo

1 Özet

Bu çalışmada, GPS'in bulunmadığı kapalı bir binada yalnızca 360 derecelik lidar ve gürültülü odometri kullanan bir drone'un, engellere çarpmadan mümkün olduğunca çok alanı keşfetmesi problemi pekiştirmeli öğrenme ile çözülmektedir. Politika, PPO (Proximal Policy Optimization) ile saf Python/numpy üzerinde kurulu hızlı bir iki boyutlu Gymnasium ortamında eğitilmiştir. Eğitim beş farklı tohum (seed) ile tekrarlanmış, eğitilmiş politika deterministik koşuda değerlendirilmiş ve sonuçlar rastgele ile basit sezgisel (heuristic) iki taban politikasına (baseline) karşı karşılaştırılmıştır. Rehberin RL'e özgü istediği gibi, **hiperparametreler (klips oranı clip_range, entropi katsayısı ent_coef, indirim faktörü γ , öğrenme hızı, değer-kaybı katsayısı vf_coef) sistematik olarak değiştirilerek yeniden eğitimler yapılmış** ve keşif-sömürü dengesine etkileri grafiklerle raporlanmıştır. Son olarak, aynı ortam, aynı beş tohum ve aynı protokol altında bir SAC ajanı da eğitilerek PPO ile birebir adil karşılaştırma yapılmış; on-policy ve off-policy ailelerinin örnek-verimliliği farkı gerçek eğrilerle gösterilmiştir. Sonuçlar, PPO ajanının her iki taban politikasını da belirgin biçimde geçtiğini ve ortalama oda kapsamasını yüksek seviyeye taşıdığını göstermektedir.

2 Giriş ve Neden Pekiştirmeli Öğrenme?

Keşif problemi, ajanın bilmediği bir haritada nereye gideceğine adım adım karar vermesini gerektirir. Bu problemin pekiştirmeli öğrenme ile çözülmesinin gerekçesi, rehberin istediği dört ölçütün de sağlanmasıdır:

Ardışıklık (eylem geleceği etkiler). Drone'un bir adımdaki dönüş ve ilerleme kararı, bir sonraki adımda göreceği lidar manzarasını ve girebileceği odaları doğrudan belirler. Yanlış bir koridora sapmak, sonraki onlarca adımın keşif potansiyelini düşürür. Durum geçişi $p(s' | s, a)$ eyleme bağlıdır.

Gecikmeli ödül. Yeni bir odaya ulaşmanın getirisi, o odaya götüren kapıyı bulmak için harcanan boş adımlardan sonra gelir. Altı odanın tamamını gezmenin büyük bonusu ise ancak bölümün sonuna doğru elde edilir. Ajan, anlık küçük cezaları göze alıp ileride büyük getiriye toplamayı öğrenmek zorundadır.

Bilinmeyen, büyük durum uzayı. Gözlem 75 boyutlu sürekli bir vektördür ve ortam stokastiktir (lidar, odometri ve rüzgar gürültüsü; zamanla yer değiştiren hareketli engeller). Durum uzayı tablo yöntemleriyle taranamayacak kadar büyüktür; bu yüzden fonksiyon yaklaşımı (sinir ağı) gerekir.

Daha ucuz bir alternatifi bulunmaması. A* veya BFS gibi klasik arama yöntemleri, haritanın ve hedefin önceden bilindiği, deterministik ve statik ortamlar için uygundur. Burada harita önceden bilinmez (ajan onu lidar ile keşfederek çıkarır), hareketli engeller ortamı zamanla değiştirir ve tek bir hedef yoktur; amaç kapsamayı en büyükmektir. Bu koşullarda klasik planlayıcılar doğrudan uygulanamaz; problem bir sıralı karar (MDP) problemidir ve pekiştirmeli öğrenme doğal çözümdür.

3 Ortam ve MDP Formülasyonu

Eğitim ortamı, mevcut Gazebo multi_room dünyasının hızlı bir iki boyutlu yaklaşımıdır (env/fast_2d_drone_env.py). Sekiz metre yarıçaplı, altı odalı bir bina, 0,5 m çözünürlüklü bir keşif ızgarası (32×32 hücre), 64 ışınlı bir lidar ve üç adet zamanla yer değiştiren hareketli engel içerir. Aynı dosya, ekipteki SAC teslimindeki ortamla

bayt-bayt ayıdır (MD5 61ec1d6a... doğrulanmıştır); böylece bütün algoritmalar birebir aynı MDP üzerinde karşılaştırılır.

Durum (gözlem) *s*. 75 boyutlu, $[0, 1]$ aralığına normalize sürekli bir vektör: 64 lidar ışını mesafesi (LIDAR_MAX=10 m'ye bölünmüş); ölçülen yönelimin kosinüs ve sinüsü (2); bir önceki eylem (v_x, v_y, ω) (3); keşif ilerlemesi ve ziyaret edilen oda oranı (2); en yakın engel mesafesi ve boşalık (idle) sayacı (2); en yakın kapıya uzaklık ve duvara yakınlık (2). Yönelim ve poz bilgisine odometri gürültüsü eklenir; yani *ölçülen* durum, *gerçek* durumdan sapar (Bölüm 10).

Eylem *a*. Üç boyutlu sürekli bir vektör, $\text{Box}(-1, 1)^3$: gövde çerçevesinde ileri/geri hız, yanıl hız ve dönüş hızı. Komutlar fiziksel sınırlara ölçeklenir ($V_{\text{MAX}}=1.2$ m/s, $W_{\text{MAX}}=1.5$ rad/s) ve üzerine rüzgar gürültüsü eklenir.

Ödül *r*. Ödül fonksiyonu koddaki `step()` metodunda (`fast_2d_drone_env.py`, 158–185. satırlar) ile birebir ayıdır:

$$\begin{aligned} r = & -0,01 + 3,0 \cdot \mathbb{I}[\text{yeni voxel}] + 20,0 \cdot \mathbb{I}[\text{yeni oda}] \\ & - 0,10 \cdot \mathbb{I}[50 \text{ adımdır yeni voxel yok}] \\ & - 0,3 \cdot \max\left(0, \frac{0,7 - \ell_{\min}}{0,7}\right) - 40,0 \cdot \mathbb{I}[\text{çarpışma}] \\ & + 60,0 \cdot \mathbb{I}[6 \text{ odanın tamamı}] - 0,10 \cdot \mathbb{I}[\text{son 60 adımda tekrar ziyaret}] \end{aligned}$$

Burada $\ell_{\min}$ en küçük lidar mesafesidir. Tasarım felsefesi, toplam getirinin yaklaşık olarak keşfedilen alanla orantılı olması, çarpışmanın ise ağır cezalandırılmasıdır. Bölüm, çarpışmada veya altı odanın tamamı gezildiğinde sonlanır (*terminated*); 600 adıma ulaşınca kesilir (*truncated*).

4 PPO Algoritması ve Hiperparametreler

PPO, aktör-kritik ailesinden **on-policy** bir politika gradyanı yöntemidir. Aktör, gözlemi alıp eylem üzerinde bir Gauss dağılımı üretir (sürekli eylem); kritik, durumun değerini tahmin eder. PPO'nun ayırt edici yanı, politika güncellemesini bir *clipped surrogate* hedefiyle sınırlamasıdır: yeni politikanın eskisine oranı $1 \pm \varepsilon$ (`clip_range=0.2`) aralığında kırılır, böylece tek adımda politikanın aşırı sapması engellenir ve eğitim kararlı kalır. Avantaj tahmini için GAE (`gae_lambda=0.95`) kullanılır.

PPO on-policy olduğu için **replay buffer yoktur**: her rollout'ta toplanan veri, birkaç epoch boyunca kullanılıp atılır. Bu, SAC/DQN gibi off-policy yöntemlere göre örnek verimliliğini düşürür; biz bunu sekiz paralel ortam (`num_envs=8`) ve daha uzun eğitim ile telafi ettik. Adil karşılaştırma için `learning_rate`, γ , ağ mimarisi ve paralel ortam sayısı SAC teslimiyle aynı tutulmuştur.

Tablo 1: PPO hiperparametreleri (`config.yaml`). Sağ sütun, Bölüm 6'de taranan değer aralığını gösterir.

Parametre	Değer	İşlevi	Tarama
<code>learning_rate</code>	3×10^{-4}	adım büyüklüğü	$10^{-4}, 3 \times 10^{-4}, 10^{-3}$
<code>n_steps</code>	1024	ortam başına rollout	–
<code>batch_size</code>	512	minibatch boyutu	–
<code>n_epochs</code>	10	rollout başına geçiş	–
<code>gamma</code> (γ)	0.98	indirim faktörü	0.95, 0.98, 0.99
<code>gae_lambda</code>	0.95	avantaj yumuşatma	–
<code>clip_range</code>	0.2	politika klips oranı	0.1, 0.2, 0.3
<code>ent_coef</code>	0.005	entropi (keşif) bonusu	0, 0.005, 0.01, 0.05
<code>vf_coef</code>	0.5	kritik kayıp ağırlığı	0.25, 0.5, 1.0
<code>max_grad_norm</code>	0.5	gradyan kırpması	–
<code>net_arch</code>	[256, 256]	ağ genişliği	–
<code>num_envs</code>	8	paralel ortam	–
<code>total_timesteps</code>	1.5 M	seed başına bütçe	–

5 Deney Düzeni

Eğitim, `seeds.txt`'teki beş tohumla (7, 13, 42, 123, 2025) tekrarlanmıştır. Her tohum için ayrı bir politika eğitilmiş; eğitim sırasında her 10.000 adımda bir deterministik eval yapılarak en iyi model saklanmıştır. Eğitim sonunda her politika, eğitimden ayrı bir RNG akışıyla (tohum+10000) **deterministik** (greedy) koşuturularak değerlendirilmiştir; çünkü eğitim eğrisi tek başına kanıt sayılmaz. Taban politikalar (rastgele ve sezgisel) aynı ortamda koşuturulmuştur.

Hiperparametre taraması (RL'e özgü, çoklu yeniden eğitim). Rehberin istediği gibi beş ayrı hiperparametre, her biri en az üç değerle ve **beş tohumla** yeniden eğitilerek taranmıştır (`clip_range`, `ent_coef`, γ , `learning_rate`, `vf_coef`; Bölüm 6). Ayrıca $\gamma \times lr$ için bir 3×3 ızgara koşuturularak ısı haritası çıkarılmıştır. Bu taramalar, hiperparametre etkisini izole etmek amacıyla kısa bütçeyle (200k/150k adım) yapılmıştır. Tüm rastgelelik `numpy.random.default_rng` ile üretilmiştir; `np.random.seed` ve `np.random.choice` kullanılmamıştır; `import gym` (eski API) yoktur.


6 Sonuçlar – Beş Zorunlu Grafik

Beş tohumun deterministik eval özeti Tablo 2'de verilmiştir. Aşağıdaki beş grafik, rehberin B bölümü zorunlu standardına uygundur: her grafikte başlık, birimli eksen etiketi, lejant, beş tohumun ortalaması ile $\pm$ standart sapma bandı ve hareketli ortalama penceresi bulunur. Öğrenme ve eval eğrilerinde y-ekseni **episode getirisidir** (anlık/per-step ödül değildir).

Tablo 2: Deterministik eval özeti (seed $\times$ metrik). Kaynak: `sonuclar/sonuclar.csv`


seed	n_ep	eval getirisi	eval std	başarı	kapsama %
7	6105	470.08	34.28	1.00	99.75
13	6007	448.82	156.79	0.90	91.98
42	6243	455.87	24.91	1.00	99.84
123	5917	443.37	114.05	0.95	95.91
2025	6133	474.58	113.19	0.95	95.94
Ort.	6081	458.5	–	0.96	96.68

Grafik 1 – Öğrenme Eğrisi




Yorum. Gözlem: Eğitim episode getirisi yaklaşık 290'dan başlayıp 0,5 milyon adımda 470 dolayına tırmanır ve 0,6 milyondan sonra 480 düzeyinde platoya oturur; tohumlar arası standart sapma bandı zamanla daralır. **Karşılaştırma:** Beş tohumun tamamı aynı seyri izler ve son üçte birde aralarındaki fark çok küçüktür, yani sonuç tohuma karşı karardır. **Açıklama:** PPO'nun clipped surrogate hedefi politikayı her güncellemede sınırlı adımlarla iyileştirdiğinden getiri düzgün ve sıçramasız artar; plato, ajanın altı odayı düzenli gezmeyi öğrenmesiyle ulaşılan tavadır. **Sonuç:** 1,5 milyon adım bu ortamda PPO için yakınsamaya fazlasıyla yeter; ek eğitim getiriyi anlamlı biçimde artırmaz (bkz. Şekil G12).

Grafik 2 – Test (Eval) Eğrisi




Yorum. Gözlem: Deterministik (greedy) eval getirisi yaklaşık 200'den 0,4 milyon adımda 470 dolayına çıkar ve eğitim eğrisiyle neredeyse aynı platoda kalır. **Karşılaştırma:** Deterministik eval, stokastik eğitim eğrisiyle aynı seviyeye oturur; aradaki fark ihmal edilebilir düzeydedir. **Açıklama:** Bu, yüksek getirinin yalnızca eğitimdeki rastgele keşif sayesinde değil, öğrenilen politikanın kendisiyle elde edildiğini gösterir; greedy koşuda da başarı korunur. **Sonuç:** Politika gerçekten genelleşmiştir ve sonuç eğitim eğrisiyle değil, ayrı bir deterministik koşuyla doğrulanmıştır (rehber B2 şartı).

Grafik 3 – Loss Eğrisi (Policy Gradient ve Value Loss)




Yorum. *Gözlem:* Value (critic) loss önce 0,3–0,4 milyon adım civarında 140 dolayında bir tepe yapar, ardından düzenli düşerek 30 seviyesine iner; policy gradient (actor) loss ise $-0,0065$ ile $-0,004$ arasında küçük kalıp yataya oturur. *Karşılaştırma:* Critic loss’un tepe-sonra-düşüş seyri, getirinin en hızlı yükseldiği döneme denk gelir. *Açıklama:* Ajan büyük ödülleri (yeni oda, altı-oda bonusu) keşfettikçe değer hedefleri büyür ve critic başta zorlanır (tepe); politika kararlılaşınca hedefler oturur ve critic loss düşer. Actor loss’un küçük ve yatay kalması, PPO’nun klips mekanizmasının güncellemeleri sınırlamasından kaynaklanır. *Sonuç:* Critic’in düşen loss’u öğrenmenin sağlıklı yakınsadığını, actor loss’un düşük ve yatay olması ise eğitimin kararlı (patlamayan) olduğunu gösterir.

Grafik 4 – Hiperparametre Duyarlılığı (beş parametre)




Yorum. *Gözlem:* Beş parametrenin her biri kendi panelinde, kısa bütçeli (200k adım, 5 tohum) koşuların final getirisiyle gösterilir; eğriler genel olarak hata bantları içinde yatay seyreder. *Karşılaştırma:* Klips oranında orta değer (0,2) en dengeli sonucu verir; çok büyük clip_range (0,3) güncellemeyi gevşetip varyansı artırır, çok küçük (0,1) ise öğrenmeyi yavaşlatır. ent_coef büyüdükçe kısa bütçede keşif artıp getiri hafifçe yükselir; γ ’da 0,98–0,99 en iyi, 0,95 gecikmeli ödülü yeterince taşımaz; learning_rate büyüdükçe kararlılık hafifçe bozulur; vf_coef orta değerde (0,5) en iyidir. *Açıklama:* Yüksek ent_coef ve uygun γ keşfi (exploration) güçlendirir; düşük learning_rate ve orta clip_range ise sömürüyü (exploitation) ve kararlılığı korur. Bu, klasik keşif–sömürü dengesidir. *Sonuç:* Seçilen taban değerler ($lr = 3 \times 10^{-4}$, ent_coef=0,005, clip_range=0,2, $\gamma = 0,98$, vf_coef=0,5) güvenli orta noktadır; sonuç bu aralıkta gürbüz olduğundan ince ayar kritik değildir.

Grafik 5 – Baseline Karşılaştırma



5b) Baseline Karşılaştırma -- Görev Metrikleri (random / heuristic / PPO)




Yorum. Gözlem: Deterministik eval ortalama getirisi PPO ajanında ~ 459 , sezgisel taban politikada ~ 402 , rastgele politikada ise ~ 49 'dur; dört metriğin (getiri, oda, kapsama, başarı) hepsinde PPO öndedir. **Karşılaştırma:** Getiri olarak PPO sezgiseli az farkla geçse de, kapsama ($\sim 96,7$ 'ye karşı $79,9$) ve tam-keşif başarısı bakımından fark çok büyüktür; rastgele politika her ölçütte çok geridedir (0 başarı). **Açıklama:** Sezgisel politika "ön açıkça ilerle" kuralıyla bazı odaları gezebilir ama kapıları planlayamaz ve sık çarpar; PPO ise lider ve öğrenilen değer fonksiyonu sayesinde hem daha çok oda gezer hem de neredeyse hiç çarpmaz. **Sonuç:** Ajanın öğrenmesi gerçek bir kazanımdır; problem basit bir kuralla veya rastgelelikle çözülemez, bu da pekiştirmeli öğrenme seçimini doğrular (rehber B5).

7 Ek Analizler

Zorunlu beş grafiğe ek olarak, ekibin sunum/raporlarındaki tüm grafiklerin PPO karşılığı ve PPO'ya özgü iç dinamikler aşağıda verilmiştir.

Grafik 6 – PPO İç Dinamikleri (klips oranı, KL, entropi)



6) PPO İç Dinamikleri -- klips oranı, KL sapması ve entropi (keşif-sömürü)



Yorum. Gözlem: Klips oranı (clip_fraction) $\sim 0,04$ 'ten $\sim 0,16$ 'ya yükselir, yaklaşık KL sapması büyür ve politika entropisi (entropy_loss) zamanla azalır (daha deterministik). **Karşılaştırma:** DQN'deki epsilon çizelgesinin PPO'daki karşılığı budur: keşiften sömürüye geçiş, sabit bir kuralla değil, entropi bonusu ve klips mekanizması üzerinden öğrenilerek olur. **Açıklama:** Başta yüksek entropi geniş keşif sağlar; politika iyileştikçe avantajlı eylemlere olasılık yığılır, entropi düşer ve daha çok güncelleme klips sınırına dayanır (artan clip_fraction). **Sonuç:** Eğrilerin patlamadan düzgün seyretmesi, klips'in güncellemeleri güvenli aralıkta tuttuğunu ve keşif-sömürü geçişinin kontrollü olduğunu gösterir.

Grafik 7 ve 8 – Oda Keşfi ve Çarpışma Oranı



Grafik 7 (Oda Keşfi). **Gözlem:** Episode başına keşfedilen ortalama oda 1'den yükselip hedef 6 odaya güçlü biçimde yaklaşır. **Açıklama:** Çarpışmadan kaçınmayı öğrenen ajan hayatta kalır ve kapıları bularak derin odalara erişir (ödüldeki $+20$ ve $+60$ terimleri). **Sonuç:** Model havada kalmayı değil, asıl amaç olan alan



taramayı da etkin yapar.

Grafik 8 (Çarpışma Oranı). *Gözlem:* Çarpışma oranı başta %100'e yakinken zamanla kararlı ve ciddi düşer. *Açıklama:* Lidar mesafesi ile -40 çarpışma cezası arasındaki ilişki ağ tarafından kurulur; kaçış davranışı değere yansır. *Sonuç:* Ajan engel algılama ve çarpışmadan sakınmayı kalıcı edinir.


Grafik 9 ve 13 – Seed Karşılaştırması ve Değer Fonksiyonu Kalitesi



Grafik 9 (Seed Karşılaştırması). *Gözlem:* Beş tohumun her biri kendine özgü yörünge izler; başlangıç hızları farklı olsa da hepsi yakın ve yüksek platoya ulaşır. *Açıklama:* Fark, başlangıç rastgeleliği ve ağırlık ilklendirmesinden gelir; ≥ 5 tohum raporlamasının gerekçesi bu varyanstır. *Sonuç:* Yakınsamanın korunması algoritmanın gürbüzlüğünü (robustness) kanıtlar.

Grafik 13 (Değer Fonksiyonu Kalitesi). *Gözlem:* Açıklanan varyans eğitim boyunca yükselip 1'e (ideal) yaklaşır. *Açıklama:* Kritik durum değerlerini giderek isabetli tahmin eder; GAE avantajları güvenilirleşir. *Sonuç:* Yüksek açıklanan varyans, politika gradyanının düşük-varyanslı ve sağlıklı güncellendiğinin niceliksel kanıtıdır.


Grafik 10 – $\gamma \times$ Öğrenme Hızı Izgarası (Isı Haritası)



Yorum. *Gözlem:* 3×3 ızgarada final getiri, keşfedilen oda ve kombinasyon skoru (10-oda + 0,05·getiri) ısı haritası olarak gösterilir. *Karşılaştırma:* En yüksek skor, orta-yüksek γ (0,98–0,99) ve düşük-orta öğrenme hızı (10^{-4} – 3×10^{-4}) köşesinde toplanır; yüksek lr ile düşük γ köşesi en zayıftır. *Açıklama:* Yüksek γ gecikmeli oda ödülünü taşıyacak ufuk sağlar; düşük lr güncellemeleri kararlı tutar. İki etki birlikte en iyi bölgeyi oluşturur. *Sonuç:* Seçilen ($\gamma=0,98$, lr= 3×10^{-4}) noktası bu en iyi bölgenin içindedir; ızgara, seçimi görsel olarak doğrular.

Grafik 11 – Tohum Bazında Detaylı Paneller

Her tohum için eğitim getirisi, final deterministik eval, keşif oranı (coverage) ve ziyaret edilen oda sayısı dört-panelli olarak sunum/grafikler/per_seed_*.png altında verilmiştir (örnek: en iyi tohum 123, aşağıda).




Yorum. *Gözlem:* En iyi tohum (123) eğitim getirisinde ~ 480 platosuna oturur; final eval barları yüksek ve dar; coverage %100'e, oda sayısı 6'ya yaklaşır. *Açıklama:* Dört panel birbirini doğrular; getiriyi artıran şey gerçekten oda ve alan kapsamasıdır (ödül tasarımı amaçlandığı gibi çalışır). *Sonuç:* Tek tohumun iç tutarlılığı, ortalama metriklerin sağlam temele dayandığını destekler.

8 PPO ve SAC Karşılaştırması

Ortam, seed listesi ve değerlendirme protokolü ekipteki SAC teslimiyle birebir aynı tutulduğundan, iki algoritma doğrudan karşılaştırılabilir. Adil ve sentetik-olmayan bir karşılaştırma için bu çalışmada **SAC ajanı da aynı beş tohumla, aynı ortamda ve aynı deterministik eval protokolüyle yeniden eğitilmiştir** (train_sac.py; ekip SAC teslimindeki hiperparametrelerle: train_freq/gradient_steps = 32/32, tau=0,02, buffer_size= 600k, ent_coef=auto). Böylece aşağıdaki eğriler gerçek ham loglardan üretilmiştir.

Tablo 3: PPO ve SAC ortalama sonuçları (5 tohum, deterministik eval; aynı ortam ve protokol)

Ölçüt	PPO (bu çalışma)	SAC (aynı ortam)
Aile	on-policy	off-policy
Replay buffer	yok	var
Eğitim adımı (ort.)	1.5 M	200 k
Eğitim episode (ort.)	~ 6081	~ 469
Ort. eval getirisi	458.5	337.0
Eval başarı oranı (6 oda)	0.96	0.34
Ort. kapsama %	96.7	92.8
Eval çarpışma oranı	0.04	0.15




Şekil 1: PPO vs SAC – öğrenme eğrisi (sol) ve örnek-verimliliği penceresi (sağ).

Yorum. *Gözlem:* Aynı ortam ve tohumlarda SAC, ilk birkaç yüz bin adımda PPO’dan daha hızlı yükselir (off-policy örnek-verimliliği); PPO ise daha çok adım karşılığında daha yüksek ve daha kararlı bir nihai platoya ulaşır. *Karşılaştırma:* Tablo 3’de PPO, dört kalite ölçütünde (getiri, başarı, kapsama, çarpışma) öndedir; SAC ise verilen kısa adım bütçesinde daha erken makul performansa erişir. *Açıklama:* Fark doğrudan algoritma ailesindendir: SAC replay buffer’daki her deneyimi defalarca kullanır (adım başına verimli), PPO her rollout’u bir kez kullanıp atar ama clipped surrogate sayesinde kararlı ve yüksek-tavanlı yakınsar. *Sonuç:* Dersin temel ayrımı somutlaşır: *off-policy (SAC) az adımda hızlı, on-policy (PPO) çok adımla yüksek nihai başarı.* Karşılaştırmanın ortam tarafı tamamen adildir.

9 Uzun-Ufuk Kararlılık (Bonus)

Eğitim bütçesinin yakınsama için yeterli olduğunu doğrulamak amacıyla en iyi tohum (123) çok daha uzun bir ufka kadar uzatılmıştır.



Yorum. *Gözlem:* Getiri, 1,5 milyon adımdaki sınırın ötesinde de plato seviyesinde kalır; belirgin bir artış veya bozulma görülmez. *Karşılaştırma:* Ana teslim bütçesi (1,5M) ile uzun koşu aynı platoya paylaşıyor. *Açıklama:* Politika bu ortamın tavanına ulaştığından, ek adımlar yalnızca varyans gürültüsü ekler; “catastrophic forgetting” veya geç yükseliş yoktur. *Sonuç:* Bu, 1,5 milyon adımın yeterli olduğunu ve seçilen bütçenin israf da eksik de olmadığını niceliksel olarak doğrular.

10 Savunma Analizi

Bu bölüm, rehberin dört kavram alanını projeye uygulayarak yanıtlar.

Deterministik mi, stokastik mi? Ortam **stokastiktir**; bu kod satırlarıyla kanıtlanır. Geçiş gürültüsü: `step()` içinde hız komutlarına $\mathcal{N}(0, \sigma_{\text{wind}})$ rüzgar eklenir; aynı (s, a) çifti farklı s' verir, yani $p(s' | s, a)$ dejenere değildir. Gözlem gürültüsü: lidar (`_compute_lidar`) ve odometri (`_make_obs`) ölçümlerine Gauss gürültüsü katılır. Bu nedenle aynı durumdan aynı eylem dizisi tekrar oynatıldığında aynı yörünge elde edilmez. Not: yalnızca başlangıç konumunun rastgele olması ortamı stokastik yapmaz; stokastiklik geçiş ve gözlem gürültüsünden gelir.

On-policy mi, off-policy mi? PPO **on-policy**'dir. Veriyi üreten davranış politikası ile iyileştirilen hedef politika aynıdır; her rollout, güncel politika ile toplanır ve güncellemeden sonra atılır. Replay buffer yoktur. Bu, SAC ve DQN'in (off-policy, replay buffer'lı) tersidir ve PPO'nun neden daha çok örnek gerektirdiğini açıklar (Bölüm 8'teki eğriler bunu somutlaştırır).

Markov özelliği. Durum, anlık lidar, yönelim, hız (önceki eylem yoluyla) ve keşif istatistiklerini içerir. Tek bir gözlem, sonraki durumun dağılımını yaklaşık olarak belirlemeye yeter; çünkü hareketli engellerin konumu adım sayısının deterministik bir fonksiyonudur ve hız bilgisi gözlemde taşınır. Yine de gürültü ve sınırlı görüş nedeniyle Markov özelliği yalnızca yaklaşık sağlanır.

Kısmi gözlemlenebilirlik (POMDP). Ortam **kısmi gözlemlenebilirdir**. Gerçek durum ile gözlem ayrışır: (i) poz/yönelim gözleme odometri gürültüsüyle girer, yani ajan gerçek konumunu tam bilmez; (ii) lidar yalnızca görüş hattındaki engelleri görür, duvar arkası bilinmez; (iii) hareketli engellerin gelecekteki konumu doğrudan gözlemde yoktur. Optimal karar için eksik olan bu bilgiyi ajan, önceki eylemi gözleme ekleyerek ve politikanın hız/yön bağlamını taşımasıyla kısmen telafi eder.

11 Sonuç

PPO, replay buffer kullanmadan, on-policy bir politika gradyanı yöntemi olarak, aynı ortamda hem rastgele hem sezgisel taban politikalarını belirgin biçimde geçmiştir. Hiperparametreler (klips, entropi, γ , öğrenme hızı, değer-kayıp katsayısı) sistematik olarak değiştirilip yeniden eğitilerek keşif-sömürü dengesine etkileri gösterilmiş; seçilen taban değerlerin gürbüz bir orta nokta olduğu doğrulanmıştır. Aynı ortamda eğitilen SAC ile karşılaştırma, on-policy/off-policy ayrımını gerçek eğrilerle somutlaştırmıştır: SAC az adımda hızlı, PPO çok adımla yüksek nihai başarı. Tüm grafikler `sonucclar/loglar/` altındaki ham loglardan yeniden üretilebilir.