

Kapalı Ortamda PPO ile Lidar Tabanlı Drone Keşfi

Pekiştirmeli Öğrenme Dönem Projesi — Teknik Sunum

Berker Yiğit — 220202046

Kocaeli Üniversitesi, Bilgisayar Mühendisliği (II. Öğretim)

Algoritma: PPO | Branch: algo/ppo

Problem ve Neden Pekiştirmeli Öğrenme?

Ortam ve MDP (durum / eylem / ödül) — SAC ile birebir aynı

PPO Algoritması ve Hiperparametreler

Deney Düzeni (5 seed, deterministik eval, baseline)

5 Zorunlu Grafik + Ek Analizler (oda keşfi, çarpışma, iç dinamikler, heatmap)

Hiperparametre Taraması (clip/ent/gamma/lr/vf — yeniden eğitim)

Per-seed Detay Panelleri

PPO vs SAC Karşılaştırması (aynı ortam/seed/protokol)

Savunma Özeti ve Sonuç

Problem ve Neden Pekiştirmeli Öğrenme?

Görev: GPS'siz kapalı binada, sadece lidar + gürültülü odometri ile çarpmadan en çok alanı keşfet.

Neden RL? (rehber dört ölçütü de sağlanır)

- Ardışıklık: bir adımdaki dönüş, sonraki adımların keşif potansiyelini belirler.
- Gecikmeli ödül: yeni oda / 6-oda bonusu ancak ileride toplanır.
- Büyük, bilinmeyen, stokastik durum uzayı (75-D sürekli; lidar/odom/rüzgar gürültüsü).
- A*/BFS uygulanamaz: harita önceden bilinmez, hareketli engeller var, tek hedef yok (amaç kapsama).

Ortam ve MDP: Durum / Eylem / Ödül

Ortam: 8 m yarıçaplı, 6 odalı bina; 64 ışınli lidar; 3 hareketli engel.

◆ SAC teslimiyle BAYT-BAYT aynı ortam (MD5 61ec1d6a); state Box(75), action Box(-1,1)³ birebir aynı.

Durum (75-D, [0,1]): 64 lidar + yaw cos/sin + önceki eylem(3) + ilerleme/oda(2) + min_lidar/idle(2) + kapı/duvar(2).

Eylem (3-D sürekli): ileri/geri hız, yanal hız, dönüş hızı.

Ödül (kod step() ile birebir): +3 yeni voxel, +20 yeni oda, -40 çarpışma, +60 tüm odalar, küçük zaman/idle cezaları.

Bölüm: çarpışma veya 6-oda ile biter, 600 adımda kesilir.

PPO Algoritması

Aktör-kritik, ON-POLICY politika gradyanı. Aktör sürekli eylemde Gauss dağılımı; kritik durum değeri.

Clipped surrogate: yeni/eski politika oranı 1 ± 0.2 ile kırıpılır => kararlı, aşırı sapmasız güncelleme.

GAE ($\lambda=0.95$) ile avantaj tahmini.

Replay buffer YOK: rollout verisi birkaç epoch kullanılıp atılır => off-policy'ye göre daha az örnek-verimli.

Telafi: 8 paralel ortam + daha uzun eğitim (1.5M adım/seed).

Adil karşılaştırma: `learning_rate`, `gamma`, ağ mimarisi, `num_envs` SAC teslimiyle AYNI.

Hiperparametreler ve Deney Düzeni

config.yaml: lr=3e-4, gamma=0.98, net=[256,256], n_steps=1024, batch=512, n_epochs=10, clip=0.2, gae=0.95, ent=0.005, vf=0.5.

5 seed: 7,13,42,123,2025 (≥ 5 zorunlu). Her seed ayrı politika; her 10k adımda deterministik eval.


Final: 20 bölüm DETERMİNİSTİK (greedy) koşu (eğitim eğrisi tek başına kanıt değil).

Baseline: rastgele + sezgisel politika, aynı ortamda.

HP taraması (yeniden eğitim): clip_range, ent_coef, gamma, learning_rate, vf_coef -> her biri ≥ 3 değer $\times$ 5 seed.


Tüm rastgelelik numpy.random.default_rng; import gym / np.random.seed YOK.

Grafik 1 — Öğrenme Eğrisi (PPO eğitim)



Grafik 1b — Öğrenme Eğrisi (x = Episode sayısı)

1b) Öğrenme Eğrisi -- x = Episode sayısı



Yorum


Gözlem: Episode ekseninde de getiri ilk birkaç bin bölümde yükselip platoya oturur.

Karşılaştırma: Adım-ekseni eğrisiyle aynı hikâye; sadece x birimi farkı (hoca: episode-bazlı eğri).

Açıklama: Bölüm uzunluğu öğrendikçe uzar (çarpışma azalır), bu yüzden episode ve adım eksenleri hafif farklı ölçeklenir.

Sonuç: Yakınsama hem adım hem episode bazında doğrulanır.

Grafik 2 — Test (Eval) Eğrisi



Yorum

Gözlem: Deterministik eval ~200'den ~0.4M'de ~470'e çıkıp eğitim platosuna oturur.


Karşılaştırma: Greedy eval ile stokastik eğitim aynı seviyede; fark ihmal edilebilir.

Açıklama: Yüksek getiri rastgele keşiften değil öğrenilen politikadan gelir; greedy'de de başarı korunur.

Sonuç: Politika genelleşmiştir; ayrı deterministik koşu ile doğrulandı (rehber B2).


Grafik 3 — Loss Eğrisi (policy gradient & value)

3) Loss Eğrisi (PPO: policy gradient & value loss)



Grafik 4 — Hiperparametre Duyarlılığı (5 parametre)


4) Hiperparametre Duyarlılığı (final episode getirisi, 5 seed) -- düşük => sömürü, yüksek => keşif



Gözlem: clip_range, ent_coef, gamma, learning_rate, vf_coef 5 tohumla tarandı; eğriler hata bandı içinde yatay. Karşılaştırma: Orta clip (0.2), 0.98–0.99 gamma ve düşük-orta lr en dengeli; uçlar varyansı artırır. Açıklama: Yüksek ent_coef/gamma keşfi (exploration), düşük lr/orta clip sömürüyü (exploitation) ve kararlılığı güçlendirir. Sonuç: Seçilen taban değerler güvenli orta nokta; sonuç bu aralıkta gürbüz.

Grafik 5 — Baseline Karşılaştırma (getiri)

5) Baseline Karşılaştırma (deterministik eval, ortalama getiri)



Yorum

Gözlem: Eval getirisi PPO ~459, heuristic ~402, random ~49.


Karşılaştırma: Getiride az fark olsa da kapsama ve çarpışma farkı çok büyük; random her ölçütte geride.

Açıklama: Heuristic kapıları planlayamaz ve sık çarpar; PPO lidar+değer ile daha çok oda gezip neredeyse hiç çarpmaz.

Sonuç: Öğrenme gerçek kazanım; problem basit kural/rastgelelikle çözülemez (rehber B5).

Grafik 5b — Baseline 4 Metrik (görev metrikleri)


5b) Baseline Karşılaştırma -- Görev Metrikleri (random / heuristic / PPO)



Gözlem: Getiri, oda, kapsama ve başarı metriklerinin dördünde de PPO önde. Karşılaştırma: Özellikle tam-keşif başarısında PPO açık ara önde; random %0 başarı. Açıklama: Görev metrikleri (oda/kapsama) sadece getiriye değil sistematik keşfe bakar; PPO bunu öğrenir. Sonuç: PPO yalnızca puan değil, gerçek görev hedefini de baskalarından iyi yapar.

Grafik 6 — PPO İç Dinamikleri (clip / KL / entropi)


6) PPO İç Dinamikleri -- klips oranı, KL sapması ve entropi (keşif→sömürü)



Gözlem: clip_fraction ~0.04'ten ~0.16'ya çıkar, approx_kl büyür, entropi azalır. Karşılaştırma: DQN'deki epsilon çizelgesinin PPO karşılığı; keşiften sömürüye geçiş ÖĞRENİLEREK olur. Açıklama: Başta yüksek entropi geniş keşif sağlar; politika iyileştikçe avantajlı eylemlere olasılık yığılır, entropi düşer. Sonuç: Eğrilerin patlamadan seyretmesi klips'in güncellemeleri güvenli tuttuğunu gösterir.

Grafik 7 — Oda Keşif Süreci

7) Oda Keşif Süreci (eğitim boyunca)



Yorum


Gözlem: Episode başına keşfedilen oda 1'den yükselip hedef 6'ya yaklaşır.

Karşılaştırma: Başta sadece doğulan oda; sonda ortalama 5-6 banda çıkar.

Açıklama: Çarpışmadan kaçınmayı öğrenen ajan hayatta kalır ve kapıları bulup derin odalara erişir (+20/+60 ödül).

Sonuç: Model havada kalmayı değil, asıl amaç olan alan taramayı da yapar.

Grafik 8 — Çarpışma Oranı



Yorum


Özet: Çarpışma oranı başta ~%100'e yakınken zamanla ciddi ve kararlı düşer.

Karşılaştırma: Per-seed eğriler aynı yönde; sonda düşük bantta sabitlenir.

Açıklama: Lidar mesafesi ile -40 çarpışma cezası ilişkisi ağ tarafından kurulur; kaçış davranışı değere yansır.

Sonuç: Ajan engel algılama ve çarpışmadan sakınmayı kalıcı olarak edinir.

Grafik 9 — Seed Karşılaştırması



Yorum

Gözlem: 5 tohumun her biri kendine özgü yörünge izler; bazıları hızlı, bazıları yavaş yükselir.


Karşılaştırma: Başlangıç hızları farklı olsa da hepsi yakın ve yüksek platoya ulaşır.

Açıklama: Fark, başlangıç pozisyonu rastgeleliği ve ağırlık ilklendirmesinden gelir; ≥ 5 tohum bu varyans için gerekli.

Sonuç: Yakınsamanın korunması algoritmanın gürbüzlüğünü (noisiness) kanıtlar.


Grafik 10 — gamma × lr Isı Haritası

10) Hiperparametre Arama -- $\gamma \times \text{learning_rate}$ Izgarası (3 seed)







Gözlem: 3×3 ızgarada getiri/oda/skor ısı haritası; en iyi bölge orta-yüksek gamma + düşük-orta lr köşesi. Karşılaştırma: Yüksek lr + düşük gamma köşesi en zayıf. Açıklama: Yüksek gamma gecikmeli oda ödülünü taşır; düşük lr güncellemeyi kararlı tutar; ikisi birlikte en iyi. Sonuç: Seçilen (gamma=0.98, lr=3e-4) bu en iyi bölgenin içinde; ızgara seçimi doğrudur.

Grafik 13 — Değer Fonksiyonu Kalitesi (explained_variance)







Tohum 123 — Detaylı Panel (getiri / eval / kapsama / oda)

Seed 123 -- Toplam 1,507,320 adım (5917 episode)







Tohum 42 — Detaylı Panel (getiri / eval / kapsama / oda)

Seed 42 -- Toplam 1,507,024 adım (6243 episode)







Tohum 7 — Detaylı Panel (getiri / eval / kapsama / oda)

Seed 7 -- Toplam 1,507,192 adım (6105 episode)







Tohum 13 — Detaylı Panel (getiri / eval / kapsama / oda)

Seed 13 -- Toplam 1,507,328 adım (6007 episode)



Tohum 2025 — Detaylı Panel (getiri / eval / kapsama / oda)

Seed 2025 -- Toplam 1,507,032 adım (6133 episode)




PPO vs SAC — Özet (aynı ortam/seed/protokol)

Ölçüt	PPO (bu çalışma)	SAC (aynı ortam)
Aile	on-policy	off-policy
Replay buffer	yok	var
Ort. eval getirisi	458.5	337.0
Başarı oranı (6 oda)	0.96	0.34
Ort. kapsama %	96.7	92.8
Eval çarpışma oranı	0.04	0.15

Ortam, durum/eylem uzayı, seed ve protokol birebir aynı -> fark yalnızca algorithmadan.

SAC az adımda hızlı oturur (off-policy, replay buffer); PPO daha çok adımla daha yüksek nihai başarı.

PPO vs SAC — Öğrenme Eğrisi



Yorum

Gözlem: SAC ilk birkaç yüz bin adımda PPO'dan hızlı yükselir; PPO daha çok adımla daha yüksek/kararlı platoya ulaşır.


Karşılaştırma: Tam ufukta PPO platosu daha yüksek.

Açıklama: SAC off-policy (replay buffer => adım başına verimli); PPO on-policy (rollout bir kez kullanılır).

Sonuç: Off-policy az adımda hızlı, on-policy çok adımla yüksek nihai başarı.

PPO vs SAC — Örnek Verimliliği

PPO vs SAC -- Örnek Verimliliği (ilk 199k adım)



Yorum

Gözlem: Aynı env-adım penceresinde SAC üstte başlar.


Karşılaştırma: SAC erken avantajlı; PPO sonradan yakalar/geçer.

Açıklama: Replay buffer her deneyimi defalarca kullandığından SAC aynı adımda daha çok öğrenir.

Sonuç: Örnek-bütçesi kısıtlı senaryolar için SAC, bütçe bolca ise PPO avantajlı.


PPO vs SAC — Deterministik Eval

PPO vs SAC -- Deterministik Eval Eğrisi



PPO vs SAC — Oda Keşif Süreci

PPO vs SAC -- Oda Keşif Süreci



Yorum

Gözlem: PPO ortalama oda sayısında 6'ya daha çok yaklaşır.


Karşılaştırma: SAC hızlı başlar ama nihai oda kapsamı PPO'nun gerisinde.

Açıklama: PPO'nun yüksek-tavanlı politikası sistematik oda-oda keşfi daha iyi yapar.

Sonuç: Görev metriğinde (oda) PPO üstün.

PPO vs SAC — Final Metrik Barları

PPO vs SAC -- Final Deterministik Eval Metrikleri (aynı ortam/protokol)



Gözlem: Getiri, oda, kapsama, başarı PPO'da yüksek; çarpışma PPO'da düşük. Karşılaştırma: Dört kalite ölçütünde PPO önde, güvenlikte (çarpışma) de daha iyi. Açıklama: Aynı ortam/seed/protokolde fark yalnızca algoritmadan gelir. Sonuç: Bu çok-odali keşif görevinde PPO nihai başarı/güvenlikte üstün.

Savunma Özeti (4 Kavram Alanı)

Stokastik mi? EVET. Kanıt kod satırı: rüzgar (step), lidar (_compute_lidar), odom (_make_obs) gürültüsü => $p(s'|s,a)$ dejenere değil.

On/Off-policy? ON-POLICY. Davranış = hedef politika; replay buffer yok; veri kullanılıp atılır.

Markov? Yaklaşık sağlanır: lidar + hız (önceki eylem) + adım-deterministik engeller; gürültü/sınırlı görüş ile yalnızca yaklaşık.

POMDP mi? EVET. Gerçek durum != gözlem: odom gürültüsü, görüş-dışı duvarlar, engelin gelecek konumu gözlemde yok.

Sonuç

PPO, on-policy ve replay buffer'sız olmasına rağmen rastgele ve sezgisel taban politikalarını belirgin geçti.
5 hiperparametre (clip/ent/gamma/lr/vf) yeniden eğitilerek tarandı; seçilen taban değerler gürbüz orta nokta.
Aynı ortamda eğitilen SAC ile kıyas, on-policy/off-policy ayrımını gerçek eğrilerle gösterdi.
Tüm grafikler sonuclar/loglar/ altındaki ham loglardan yeniden üretilebilir.