

Kapalı Ortamda PPO ile Lidar Tabanlı Drone Keşfi

Pekiştirmeli Öğrenme Dönem Projesi — Teknik Sunum

Berker Yiğit — 220202046

Kocaeli Üniversitesi, Bilgisayar Mühendisliği (II. Öğretim)

Algoritma: PPO | Branch: algo/ppo

Problem ve Neden Pekiştirmeli Öğrenme?

Ortam ve MDP (durum / eylem / ödül) — SAC ile birebir aynı

PPO Algoritması ve Hiperparametreler

Deney Düzeni (5 seed, deterministik eval, baseline)

5 Zorunlu Grafik + Ek Analizler (oda keşfi, çarpışma, iç dinamikler, heatmap)

Hiperparametre Taraması (clip/ent/gamma/lr/vf — yeniden eğitim)

Per-seed Detay Panelleri

PPO vs SAC Karşılaştırması (aynı ortam/seed/protokol)

Savunma Özeti ve Sonuç

Problem ve Neden Pekiştirmeli Öğrenme?

Görev: GPS'siz kapalı binada, sadece lidar + gürültülü odometri ile çarpmadan en çok alanı keşfet.

Neden RL? (rehber dört ölçütü de sağlanır)

- Ardışıklık: bir adımdaki dönüş, sonraki adımların keşif potansiyelini belirler.
- Gecikmeli ödül: yeni oda / 6-oda bonusu ancak ileride toplanır.
- Büyük, bilinmeyen, stokastik durum uzayı (75-D sürekli; lidar/odom/rüzgar gürültüsü).
- A*/BFS uygulanamaz: harita önceden bilinmez, hareketli engeller var, tek hedef yok (amaç kapsama).

Ortam ve MDP: Durum / Eylem / Ödül

Ortam: 8 m yarıçaplı, 6 odalı bina; 64 ışınlı lidar; 3 hareketli engel.

◆ SAC teslimiyle BAYT-BAYT aynı ortam (MD5 61ec1d6a); state Box(75), action Box(-1,1)³ birebir aynı.

Durum (75-D, [0,1]): 64 lidar + yaw cos/sin + önceki eylem(3) + ilerleme/oda(2) + min_lidar/idle(2) + kapı/duvar(2).

Eylem (3-D sürekli): ileri/geri hız, yanıl hız, dönüş hızı.

Ödül (kod step() ile birebir): +3 yeni voxel, +20 yeni oda, -40 çarpışma, +60 tüm odalar, küçük zaman/idle cezaları.

STOKASTİK: rüzgar $\sigma=0.015$ (geçiş, satır 133-135) + lidar $\sigma=0.015$ + odometri $\sigma=0.004$ (gözlem) + 3 hareketli engel $\rightarrow p(s'|s,a)$ dejenere değil.

Bölüm: çarpışma veya 6-oda ile biter, 600 adımda kesilir.

PPO Algoritması

Aktör-kritik, ON-POLICY politika gradyanı. Aktör sürekli eylemde Gauss dağılımı; kritik durum değeri.

Clipped surrogate: yeni/eski politika oranı 1 ± 0.2 ile kırıpılır => kararlı, aşırı sapmasız güncelleme.

GAE ($\lambda=0.95$) ile avantaj tahmini.

Replay buffer YOK: rollout verisi birkaç epoch kullanılıp atılır => off-policy'ye göre daha az örnek-verimli.

Telafi: 8 paralel ortam + daha uzun eğitim (1.5M adım/seed).

Adil karşılaştırma: `learning_rate`, `gamma`, ağ mimarisi, `num_envs` SAC teslimiyle AYNI.

Hiperparametreler ve Deney Düzeni

config.yaml: lr=3e-4, gamma=0.98, net=[256,256], n_steps=1024, batch=512, n_epochs=10, clip=0.2, gae=0.95, ent=0.005, vf=0.5.

5 seed: 7,13,42,123,2025 (≥ 5 zorunlu). Her seed ayrı politika; her 10k adımda deterministik eval.


Final: 20 bölüm DETERMİNİSTİK (greedy) koşu (eğitim eğrisi tek başına kanıt değil).

Baseline: rastgele + sezgisel politika, aynı ortamda.

HP taraması (yeniden eğitim): clip_range, ent_coef, gamma, learning_rate, vf_coef -> her biri ≥ 3 değer $\times$ 5 seed.


Tüm rastgelelik numpy.random.default_rng; import gym / np.random.seed YOK.

Grafik 1 — Öğrenme Eğrisi (PPO eğitim)



Grafik 1b — Öğrenme Eğrisi (x = Episode sayısı)

1b) Öğrenme Eğrisi -- x = Episode sayısı



Yorum


Gözlem: Episode ekseninde de getiri ilk birkaç bin bölümde yükselip platoya oturur.

Karşılaştırma: Adım-ekseni eğrisiyle aynı hikâye; sadece x birimi farkı (hoca: episode-bazlı eğri).

Açıklama: Bölüm uzunluğu öğrendikçe uzar (çarpışma azalır), bu yüzden episode ve adım eksenleri hafif farklı ölçeklenir.

Sonuç: Yakınsama hem adım hem episode bazında doğrulanır.

Grafik 2 — Test (Eval) Eğrisi



Yorum

Gözlem: Deterministik eval ~200'den ~0.4M'de ~470'e çıkıp eğitim platosuna oturur.


Karşılaştırma: Greedy eval ile stokastik eğitim aynı seviyede; fark ihmal edilebilir.

Açıklama: Yüksek getiri rastgele keşiften değil öğrenilen politikadan gelir; greedy'de de başarı korunur.

Sonuç: Politika genelleşmiştir; ayrı deterministik koşu ile doğrulandı (rehber B2).

Grafik 3 — Loss Eğrisi (policy gradient & value)

3) Loss Eğrisi (PPO: policy gradient & value loss)



Yorum

Gözlem: Critic (value) loss ~0.3M'de ~140 tepe yapıp ~30'a düşer; actor loss küçük ve yatay.


Karşılaştırma: Critic tepesi getirinin en hızlı yükseldiği döneme denk gelir.

Açıklama: Büyük ödülleri keşfedilince değer hedefleri büyür (critic zorlanır) politika oturunca düşer. Actor küçük çünkü klips güncellemeyi sınırlar.

Sonuç: Critic loss düşüşü sağlıklı yakınsama, actor loss yataylık kararlılığı gösterir.

Grafik 4 — Hiperparametre Duyarlılığı (5 parametre)


4) Hiperparametre Duyarlılığı (final episode getirisi, 5 seed) -- düşük => sömürü, yüksek => keşif



Gözlem: clip_range, ent_coef, gamma, learning_rate, vf_coef 5 tohumla tarandı; eğriler hata bandı içinde yatay. Karşılaştırma: Orta clip (0.2), 0.98–0.99 gamma ve düşük-orta lr en dengeli; uçlar varyansı artırır. Açıklama: Yüksek ent_coef/gamma keşfi (exploration), düşük lr/orta clip sömürüyü (exploitation) ve kararlılığı güçlendirir. Sonuç: Seçilen taban değerler güvenli orta nokta; sonuç bu aralıkta gürbüz.

Grafik 5 — Baseline Karşılaştırma (getiri)

5) Baseline Karşılaştırma (deterministik eval, ortalama getiri)



Yorum

Gözlem: Eval getirisi PPO ~459, heuristic ~402, random ~49.


Karşılaştırma: Getiride az fark olsa da kapsama ve çarpışma farkı çok büyük; random her ölçütte geride.

Açıklama: Heuristic kapıları planlayamaz ve sık çarpar; PPO lidar+değer ile daha çok oda gezip neredeyse hiç çarpmaz.

Sonuç: Öğrenme gerçek kazanım; problem basit kural/rastgelelikle çözülemez (rehber B5).

Grafik 5b — Baseline 4 Metrik (görev metrikleri)


5b) Baseline Karşılaştırma -- Görev Metrikleri (random / heuristic / PPO)



Gözlem: Getiri, oda, kapsama ve başarı metriklerinin dördünde de PPO önde. Karşılaştırma: Özellikle tam-keşif başarısında PPO açık ara önde; random %0 başarı. Açıklama: Görev metrikleri (oda/kapsama) sadece getiriye değil sistematik keşfe bakar; PPO bunu öğrenir. Sonuç: PPO yalnızca puan değil, gerçek görev hedefini de baskalarından iyi yapar.

Grafik 6 — PPO İç Dinamikleri (clip / KL / entropi)


6) PPO İç Dinamikleri -- klips oranı, KL sapması ve entropi (keşif→sömürü)



Gözlem: clip_fraction ~0.04'ten ~0.16'ya çıkar, approx_kl büyür, entropi azalır. Karşılaştırma: DQN'deki epsilon çizelgesinin PPO karşılığı; keşiften sömürüye geçiş ÖĞRENİLEREK olur. Açıklama: Başta yüksek entropi geniş keşif sağlar; politika iyileştikçe avantajlı eylemlere olasılık yığılır, entropi düşer. Sonuç: Eğrilerin patlamadan seyretmesi klips'in güncellemeleri güvenli tuttuğunu gösterir.

Grafik 7 — Oda Keşif Süreci

7) Oda Keşif Süreci (eğitim boyunca)



Yorum


Gözlem: Episode başına keşfedilen oda 1'den yükselip hedef 6'ya yaklaşır.

Karşılaştırma: Başta sadece doğulan oda; sonda ortalama 5-6 banda çıkar.

Açıklama: Çarpışmadan kaçınmayı öğrenen ajan hayatta kalır ve kapıları bulup derin odalara erişir (+20/+60 ödül).

Sonuç: Model havada kalmayı değil, asıl amaç olan alan taramayı da yapar.

Grafik 8 — Çarpışma Oranı



Yorum


Özet: Çarpışma oranı başta ~%100'e yakınken zamanla ciddi ve kararlı düşer.

Karşılaştırma: Per-seed eğriler aynı yönde; sonda düşük bantta sabitlenir.

Açıklama: Lidar mesafesi ile -40 çarpışma cezası ilişkisi ağ tarafından kurulur; kaçış davranışı değere yansır.


Sonuç: Ajan engel algılama ve çarpışmadan sakınmayı kalıcı olarak edinir.

Grafik 9 — Seed Karşılaştırması




Grafik 10 — gamma × lr Isı Haritası

10) Hiperparametre Arama -- $\gamma \times \text{learning_rate}$ Izgarası (3 seed)







Gözlem: 3×3 ızgarada getiri/oda/skor ısı haritası; en iyi bölge orta-yüksek gamma + düşük-orta lr köşesi. Karşılaştırma: Yüksek lr + düşük gamma köşesi en zayıf. Açıklama: Yüksek gamma gecikmeli oda ödülünü taşır; düşük lr güncellemeyi kararlı tutar; ikisi birlikte en iyi. Sonuç: Seçilen (gamma=0.98, lr=3e-4) bu en iyi bölgenin içinde; ızgara seçimi doğrudur.

Grafik 13 — Değer Fonksiyonu Kalitesi (explained_variance)







Tohum 123 — Detaylı Panel (getiri / eval / kapsama / oda)

Seed 123 -- Toplam 1,507,320 adım (5917 episode)







Tohum 42 — Detaylı Panel (getiri / eval / kapsama / oda)

Seed 42 -- Toplam 1,507,024 adım (6243 episode)







Tohum 7 — Detaylı Panel (getiri / eval / kapsama / oda)

Seed 7 -- Toplam 1,507,192 adım (6105 episode)







Tohum 13 — Detaylı Panel (getiri / eval / kapsama / oda)

Seed 13 -- Toplam 1,507,328 adım (6007 episode)



Tohum 2025 — Detaylı Panel (getiri / eval / kapsama / oda)

Seed 2025 -- Toplam 1,507,032 adım (6133 episode)



PPO vs SAC — Özet (aynı ortam/seed/protokol)

Ölçüt	PPO (bu çalışma)	SAC (M.A. Albayrak, 220202082)
Aile	on-policy	off-policy
Replay buffer	yok	var
Ort. getiri (5 tohum)	458.5	314.6
Ort. oda (/6)	5.80	4.83
Tam-keşif başarı oranı	0.96	0.34
En iyi tohum getirisi	474.6	393.7

Ortam, durum/eylem uzayı, seed ve protokol birebir aynı -> fark yalnızca algorithmadan.


SAC az adımda hızlı oturur (off-policy, replay buffer); PPO daha çok adımla daha yüksek nihai başarı.

PPO ↔ SAC — Öğrenme Eğrisi

PPO ↔ SAC — Öğrenme Eğrisi (episode getirisi)


PPO — bu çalışma (Berker, 220202046)

1) Öğrenme Eğrisi (PPO eğitim)



SAC — M. A. Albayrak (220202082)

Seed 123 — Öğrenme Eğrisi (eğitim, 1,709,864 adım)




Sol PPO (bu çalışma), sağ SAC (M.A. Albayrak). PPO platosu (~480) SAC'ın (~390) üzerinde ve daha kararlı; SAC off-policy olduğu için daha az adımda yakınsar (örnek-verimli).

PPO ↔ SAC — Tohum 123 Detay Paneli

PPO ↔ SAC — Tohum 123 Detay Paneli (getiri / eval / kapsama / oda)


PPO — bu çalışma (Berker, 220202046)

Seed 123 -- Toplam 1,507,320 adım (5917 episode)



SAC — M. A. Albayrak (220202082)

Seed 123 — Toplam 1,709,864 adım (3806 episode)




Dört panelde de (getiri/eval/kapsama/oda) PPO eğrileri daha yüksek ve daha az dalgalı; ikisi de coverageı %90+ ve odayı 5-6'ya taşır. İki algoritma da görevi çözer, PPO daha yüksek tavanla.

PPO ↔ SAC — Baseline (görev metrikleri)

PPO ↔ SAC — Baseline Karşılaştırma (görev metrikleri)


PPO — bu çalışma (Berker, 202020246)

5b) Baseline Karşılaştırma -- Görev Metrikleri (random / heuristic / PPO)



SAC — M. A. Albayrak (20202082)

5) Baseline Karşılaştırması — Rastgele / Heuristik / SAC (deterministik eval)




Her ikisi de rastgele/sezgiseli geçer; tam-keşif başarısında PPO (~%96) SAC'ın (~%60 en iyi, %34 ort.) belirgin önünde.

PPO ↔ SAC — Hiperparametre Duyarlılığı

PPO ↔ SAC — Hiperparametre Duyarlılığı


PPO — bu çalışma (Berker, 220202046)

4) Hiperparametre Duyarlılığı (final episode getirisi, 5 seed) -- düşük => sömürü, yüksek => keşif



SAC — M. A. Albayrak (220202082)

4) Hiperparametre Duyarlılığı (eğitim sonu, seed ortalaması ± std)




İki algoritmada da orta hiperparametre değerleri en iyi (keşif-sömürü dengesi); sonuç ince ayara aşırı duyarlı değil.

PPO ↔ SAC — Loss Eğrileri

PPO ↔ SAC — Loss Eğrisi (actor & critic)


PPO — bu çalışma (Berker, 220202046)

3) Loss Eğrisi (PPO: policy gradient & value loss)



SAC — M. A. Albayrak (220202082)

Seed 123 — Loss Eğrisi (actor & critic, pencere=30)




PPO'da klips güncellemeleri sıkı sınırlar (actor loss küçük/yatay); SAC'ta entropi+replay ile loss daha geniş salınır. İkisi de kararlı.

PPO ↔ SAC — $\gamma \times \text{lr}$ Araması

PPO ↔ SAC — $\gamma \times \text{learning_rate}$ Hiperparametre Arama

PPO — bu çalışma (Berker, 20202046)

10) Hiperparametre Arama -- $\gamma \times \text{learning_rate}$ Izgarası (3 seed)



SAC — M. A. Albayrak (20202082)

Hiperparametre Arama Sonuçları (seed=42, 200k adım)



Her ikisinde de en iyi bölge orta-yüksek γ + düşük-orta lr köşesi; ortamın paylaşılan yapısını (gecikmeli oda ödülü) yansıtır.

Savunma 1 — Deterministik mi, Stokastik mi? → STOKASTİK

Tanım: ortam stokastik $\Leftrightarrow p(s' | s, a)$ dejenere DEĞİL — aynı (s, a) farklı s' üretebilir.

Stokastikliği sağlayan değerler (kod satırı ile):

- Rüzgar $\sigma=0.015 \rightarrow$ hız komutuna eklenir: $v_x, v_y, \omega += N(0, 0.015)$ [step(), satır 133-135] — GEÇİŞ gürültüsü.
- Lidar $\sigma=0.015 \rightarrow$ her ışın mesafesine [_compute_lidar, 319-320] — gözlem gürültüsü.
- Odometri $\sigma=0.004 \rightarrow$ ölçülen poz/yaw'a [_make_obs, 233-236] — gözlem gürültüsü.
- 3 hareketli engel, sinüzoidal/zaman-değişken [_moving_obstacles, 203-206].

Örnek: drone (5,5), eylem 'tam ileri'. Gürültüsüz $s'=(5.144, 5.0)$; ama $v_x += \epsilon \rightarrow$ her oynatımda farklı $\rightarrow s'$ bir DAĞILIM (tek nokta değil).

Aynı tohum = sadece TEKRARLANABİLİRLİK (deterministik değil). Başlangıç rastgeleliği TEK BAŞINA stokastiklik değildir; stokastiklik geçiş+gözlem gürültüsünden gelir.

Savunma 2 — On-policy mi, Off-policy mi? → ON-POLICY

Davranış politikası = hedef politika (aynı π_θ). Veri güncel π_θ ile toplanır, n_epochs sonra ATILIR; replay buffer YOK.

Bu on-policy'nin tanımı; SAC/DQN'in (replay buffer'lı off-policy) tersi.

Neden örnek-verimsiz? Her veri yalnız 1 kez kullanılır; politika değişince eski veri off-policy olup atılır → daha çok çevre etkileşimi (8 paralel ortam telafi).

SARSA vs Q-Learning (tek satır fark): SARSA hedefi $Q(s',a')$ (davranıştan a' , on-policy); Q-Learning $\max_a Q(s',a)$ (greedy hedef, off-policy).

Off-policy avantajı: replay ile veriyi tekrar kullanır (örnek-verimli); riski: eski veri güncel politikadan sapabilir (kararlılık).

Savunma 3 — Markov Özelliği? → YAKLAŞIK Markov

Tanım: $P(s_{t+1} | s_t, a_t) = P(s_{t+1} | s_t, a_t, \dots, s_0)$ — gelecek yalnız şimdiki duruma bağlı, geçmişe değil.

Durumda önceki eylem(3) VAR → HIZ/momentum bilgisini taşır (top örneği: yalnız konum Markov değil, konum+hız Markov).

Eksik bilgi: hareketli engel konumu t'nin fonksiyonu ($\sin(2\pi t/T)$) ama durum t'yi/engel fazını AÇIKÇA içermez → engelin gelecek yeri tek gözlemden tam belirlenemez → YAKLAŞIK Markov.

Atari: tek kare hızı vermez (Markov değil), DeepMind 4 kare istifledi; bizdeki karşılık önceki eylemi durumda tutmak.

Markov değilse 2 çözüm: (i) durumu zenginleştir (hız/faz ekle — biz önceki eylemi ekledik), (ii) bellek (RNN/LSTM, kare istifleme).

Savunma 4 — Kısmi Gözlemlenebilir mi? → EVET (POMDP)

Gerçek durum s : drone'un GERÇEK konum/yaw'ı, TÜM engellerin gerçek konumu, haritanın tam geometrisi.

Gözlem o : GÜRÜLTÜLÜ lidar (yalnız görüş hattı) + GÜRÜLTÜLÜ odometri poz/yaw + keşif istatistikleri.

Aradaki boşluk (eksik bilgi): (i) odom gürültüsü → ajan gerçek konumu TAM bilmez; (ii) lidar duvar ARKASINI görmez; (iii) engelin GELECEK konumu gözlemde yok.

Gözlem gürültüsü tek başına değil; asıl POMDP sınırlı görüşten (duvar arkası) gelir. Vanilla DQN yetersiz → bellek (RNN) veya gözlem istifleme gerekir.

Belief state: gerçek durum üzerindeki olasılık dağılımı (inanç); gözlemlerle Bayes ile güncellenir, POMDP'de optimal politika belief üzerinde tanımlıdır. Biz önceki eylem + politika bağlamıyla KISMEN telafi ederiz.

Sonuç

PPO, on-policy ve replay buffer'sız olmasına rağmen rastgele ve sezgisel taban politikalarını belirgin geçti.
5 hiperparametre (clip/ent/gamma/lr/vf) yeniden eğitilerek tarandı; seçilen taban değerler gürbüz orta nokta.
Akif'in yayınlanmış SAC grafikleriyle yan-yana kıyas, on-policy/off-policy ayrımını gösterdi.
Tüm grafikler sonuclar/loglar/ altındaki ham loglardan yeniden üretilebilir.