

Konu: Lidar ve Odometri Tabanlı Drone ile Oda Keşfi ve Navigasyon

Hazırlayanlar:

Berker Yiğit - 220202046, Mehmet Akif Albayrak - 220202082,

Berk Karaoğlu - 220202079, Kürşat Emircan Balta - 220202065

1. Proje Tanımı ve Amaç

Bu projede, kapalı bir iç mekânda (çok odalı bir yapı) hareket eden otonom bir drone'un, lidar ve odometri verilerini kullanarak yeni odaları keşfetmesi ve çarpışmadan ilerlemesi amaçlanmaktadır. Ortamda odalar birbirine kapılarla bağlıdır ve bu kapılar zamanla açılıp kapanabilmektedir. Ayrıca ortamda hareketli engeller ve rastgele etkiler (örneğin rüzgâr ve lidar gürültüsü) bulunarak problem stokastik hale getirilecektir.

Drone'un temel amacı:

- Daha önce keşfedilmemiş alanları bulmak
- Odalar arasında geçiş yapmak
- Çarpışmadan maksimum alanı taramak

Bu problem, klasik robot navigasyon problemlerine benzer olmakla birlikte, keşif (exploration) odaklı olması nedeniyle pekiştirmeli öğrenme için uygundur.

2. Kullanılacak Ortam ve Teknolojiler

Projede simülasyon ortamı olarak **Gazebo Harmonic** ve robot kontrol altyapısı olarak **Robot Operating System (ROS)** kullanılacaktır. Sistem Ubuntu işletim sistemi üzerinde çalıştırılacaktır.

Gazebo ortamında:

- Çok odalı bir yapı oluşturulacaktır
- Kapılar dinamik olarak açılıp kapanacaktır
- Hareketli engeller eklenecektir
- Gürültü (noise) ile stokastik davranış sağlanacaktır

3. Problem Tanımı (MDP Formülasyonu)

Problem bir Markov Decision Process (MDP) olarak modellenmiştir.

State (s)

Durum uzayı aşağıdaki bileşenlerden oluşmaktadır:

- Lidar sensör verisi (mesafe ölçümleri)
- Drone'un odometrik bilgisi (pozisyon ve yönelim)
- Yakın çevreye dair dolaylı çevresel bilgi (engel yoğunluğu vb.)

Action (a)

Projede iki farklı eylem uzayı yaklaşımı kullanılacaktır:

Continuous Action Space

- Lineer hız (v)
- Açısal hız (ω)

Discrete Action Space

- İleri git
- Sola dön
- Sağa dön
- Dur / hover

Reward (r)

Ödül fonksiyonu keşif ve güvenli navigasyonu teşvik edecek şekilde tasarlanmıştır.

Değerler sonradan değiştirilebilecek şekilde örnek olarak verilmiştir.

- Yeni alan keşfi: +1
- Yeni odaya geçiş: +15
- Çarpışma: -10
- Engele çok yaklaşma: -0.5
- Aynı bölgede kalma: -0.1

Bu yapı, ajanı hem keşfe teşvik eder hem de güvenli hareket etmeye zorlar.

Transition Probability (P)

Ortam deterministik değildir, stokastiktir. Bunun sebepleri:

- Hareketli engellerin varlığı
- Kapıların zamanla açılıp kapanması
- Simülasyona eklenecek drone hareketleri ve lidar verilerinde gürültü. Bu nedenle aynı aksiyon her zaman aynı sonucu üretmez.

4. Model-Free Yaklaşım

Projede **model-free pekiştirmeli öğrenme** yöntemleri kullanılacaktır.

Sebepler:

- Ortamın dinamik ve karmaşık olması
- Geçiş olasılıklarının açıkça modellenmesinin zor olması
- Gerçek dünyaya daha uygun bir öğrenme yaklaşımı sunması

Ajan, çevreyle etkileşime girerek ödül fonksiyonundan öğrenme gerçekleştirecektir.

5. Deterministik vs Stokastik Problem

Bu problem **stokastik** olarak tanımlanmıştır.

Stokastik yaklaşımın tercih edilme nedenleri:

- Gerçek dünya koşullarını daha iyi modellemesi
- RL algoritmalarının belirsizlik altında öğrenme kabiliyetini test etmesi
- Ajanın daha genellenebilir politikalar öğrenmesini sağlaması

6. Algoritma Seçimi ve Dağılımı

Projede her bir ekip üyesi farklı bir pekiştirmeli öğrenme algoritması kullanacaktır. Bu yaklaşımın temel amacı, aynı ortam ve görev üzerinde farklı algoritmaların performansını karşılaştırarak hem yöntemlerin güçlü/zayıf yönlerini analiz etmek hem de action space seçiminin öğrenme sürecine etkisini incelemektir.

Algoritma seçimi yapılırken aşağıdaki kriterler dikkate alınmıştır:

- Action space (continuous / discrete) uyumluluğu
- Eğitim stabilitesi
- Örnek verimliliği (sample efficiency)
- Literatürdeki başarı durumu
- Uygulanabilirlik (Gazebo + ROS ortamında çalıştırılabilirlik)

Continuous Action Space Kullananlar

Mehmet Akif Albayrak → TD3 (Twin Delayed Deep Deterministic Policy Gradient)

TD3, continuous action space problemleri için geliştirilmiş, DDPG algoritmasının iyileştirilmiş bir versiyonudur. Yapılan literatür incelemesinde, DDPG'nin yüksek varyans ve overestimation bias gibi problemler yaşadığı, TD3'ün ise bu sorunları üç temel mekanizma ile azalttığı görülmüştür:

- Twin critic yapısı ile Q-value overestimation azaltılması
- Gecikmeli policy güncellemeleri (delayed updates) ile daha stabil öğrenme
- Target policy smoothing ile daha robust davranış

Drone kontrolü gibi hassas ve sürekli kontrol gerektiren problemlerde TD3'ün daha stabil sonuçlar verdiği bilinmektedir. Bu nedenle continuous kontrolün daha zorlayıcı olduğu senaryoda, daha gelişmiş ve stabil bir yöntem olarak TD3 tercih edilmiştir.

Berker Yiğit → PPO (Proximal Policy Optimization)

PPO, günümüzde en yaygın kullanılan policy gradient tabanlı algoritmalarından biridir ve hem discrete hem de continuous action space'lerde başarılı şekilde uygulanabilmektedir. Yapılan araştırmalarda PPO'nun aşağıdaki avantajları öne çıkmaktadır:

- Clipping mekanizması sayesinde stabil ve kontrollü policy güncellemesi
- Hyperparameter hassasiyetinin diğer algoritmalara göre daha düşük olması
- Farklı ortamlarda (robotik, oyun, simülasyon) genellenebilirlik

Continuous action space için PPO'nun Gaussian policy ile doğal bir şekilde uygulanabilmesi, bu projede tercih edilmesinin önemli sebeplerindendir. Ayrıca TD3 gibi daha hassas algoritmalarla karşılaştırıldığında, PPO'nun daha stabil ve güvenilir bir baseline oluşturduğu düşünülmektedir. Bu nedenle continuous ortamda hem güçlü hem de karşılaştırma açısından anlamlı bir yöntem olarak seçilmiştir.

Discrete Action Space Kullananlar

Berk Karaoğlu → DQN (Deep Q-Network)

DQN, value-based yöntemler arasında en temel ve en yaygın kullanılan algoritmalarından biridir. Discrete action space problemleri için oldukça uygun bir yapı sunar. Yapılan incelemelerde DQN'in aşağıdaki avantajları öne çıkmıştır:

- Q-learning tabanlı olması nedeniyle yorumlanabilirlik
- Replay buffer kullanımı ile daha verimli öğrenme
- Target network ile stabilite sağlanması

Bu projede DQN'in tercih edilmesinin temel amacı, discrete action space için güçlü bir baseline oluşturmaktır. Daha karmaşık yöntemlerle karşılaştırıldığında, DQN'in performansı referans noktası olarak kullanılacaktır. Ayrıca implementasyonunun görece daha basit olması, sistemin ilk aşamada doğrulanmasını kolaylaştıracaktır.

Kürşat Emircan Balta → A3C (Asynchronous Advantage Actor-Critic)

A3C, hem policy-based hem value-based yaklaşımları birleştiren actor-critic mimarisine sahip bir algoritmadır. En önemli özelliği, paralel çalışan birden fazla ajan sayesinde öğrenme sürecini hızlandırmasıdır.

Araştırmalar sonucunda A3C'nin şu avantajları belirlenmiştir:

- Paralel öğrenme sayesinde daha hızlı convergence
- Advantage function kullanımı ile daha düşük varyans
- Exploration kabiliyetinin yüksek olması

Bu projede ortamın stokastik olması ve keşif (exploration) gerektirmesi nedeniyle A3C'nin avantajlı olacağı öngörülmektedir. DQN'e kıyasla daha dinamik bir öğrenme süreci sunması, özellikle karmaşık ortam davranışlarında fark yaratabilir. Bu nedenle discrete action space içinde daha gelişmiş bir alternatif olarak seçilmiştir.

Genel Değerlendirme

Seçilen algoritmalar, farklı RL yaklaşım türlerini temsil edecek şekilde bilinçli olarak dağıtılmıştır:

- **Value-based:** DQN
- **Policy-based:** PPO
- **Actor-Critic:** A3C, TD3

Bu çeşitlilik sayesinde:

- Continuous vs discrete action space karşılaştırması yapılabilecek
- Farklı öğrenme paradigmalarının performansı analiz edilebilecek
- Aynı problem üzerinde algoritmaların davranış farkları gözlemlenebilecektir

Bu yapı, projenin sadece bir uygulama olmasının ötesine geçerek karşılaştırmalı bir çalışma niteliği kazanmasını sağlamaktadır.

7. Beklenen Sonuçlar

Projeden beklenen çıktılar:

- Drone'un çarpışmadan keşif yapabilmesi
- Farklı algoritmaların performans karşılaştırması
- Continuous vs discrete action space etkisinin analizi
- Stokastik ortamda öğrenme başarımının incelenmesi

8. Sonuç

Bu proje, pekiştirmeli öğrenmenin gerçekçi bir robotik problem üzerinde uygulanmasını hedeflemektedir. Gazebo ve ROS kullanılarak oluşturulan simülasyon ortamı sayesinde, farklı RL algoritmalarının performansı karşılaştırılacak ve action space seçimlerinin öğrenme üzerindeki etkileri analiz edilecektir.

Bu yönüyle proje, hem teorik hem de uygulamalı açıdan kapsamlı bir çalışma sunmaktadır.