

# Pekiştirmeli Öğrenme Dersi Proje Raporu

Ad – Soyad: Berk Karaoğlu

Öğrenci No: 220202079

## 1. Metodolojik Yaklaşım: Neden Derin Pekiştirmeli Öğrenme?

İnsansız Hava Araçlarının (İHA) karmaşık iç mekanlarda otonom keşif yapabilmesi, yüksek derecede belirsizlik ve dinamik değişkenler içeren bir kontrol problemidir. Bu çalışmada, Dijkstra, BFS veya A\* gibi klasik yol planlama algoritmaları yerine Derin Pekiştirmeli Öğrenme (DQN) mimarisinin tercih edilmesi stratejik bir gerekliliktir. Geleneksel arama algoritmaları genellikle deterministik ve statik ortam varsayımlarıyla çalışırken; otonom keşif süreci, gerçek dünya fiziğinin stokastik doğasını yansıtan gürültülü verilerle başa çıkmak zorundadır.

Sistemin DQN tercihini zorunlu kılan teknik gereklilikleri şu şekilde kategorize edilebilir:

- **Stokastik Ortam Dinamikleri:** Ortamda İHA hızına doğrudan etki eden rüzgar gürültüsü ( $\sigma = 0.015$ ) ve hareketli engeller bulunmaktadır. "Random start = true" konfigürasyonu, ajanın ezberlenmiş bir rota yerine her başlangıç koşulunda geçerli olan genel bir kurtarma politikası (policy) ve genelleştirme (generalization) yeteneği geliştirmesini sağlamıştır.
- **Kısmi Gözlemlenebilirlik (POMDP):** Ajan haritayı bütüncül bir şekilde görmek yerine; gürültülü Lidar ( $\sigma = 0.015$ ) ve Odometri ( $\sigma = 0.004$ ) sensörlerinden gelen kısıtlı verilerle durum tahmini yapmak durumundadır.
- **Sürekli Uzay ve Gecikmeli Ödüller:** İHA, ayrık kare ızgaralar yerine sürekli koordinat düzleminde (X, Y, Yaw) hareket etmektedir. Ayrıca, anlık bir manevranın stratejik sonucu (örn: oda keşfi) zaman serisinde çok daha sonra ortaya çıkmaktadır.

Bu karmaşık çevresel faktörlerin üstesinden gelmek ve ajanı istenen hedeflere yönlendirmek için tasarlanan matematiksel ödül yapısı, sistemin karar mekanizmasının temelini oluşturmaktadır.

## 2. Ödül (Reward) Fonksiyonu ve Matematiksel Modelleme

Pekiştirmeli öğrenme sürecinde ödül fonksiyonu, ajanın "hayatta kalma" içgüdüğü ile "keşfetme" motivasyonu arasındaki hassas dengeyi kuran en kritik bileşendir. Ajanın her zaman adımında aldığı toplam anlık ödül ( $R_t$ ), aşağıda belirtilen çok boyutlu formülasyon ile hesaplanır:

$$R_t = r_{\text{zaman}} + r_{\text{keşif}} + r_{\text{oda}} + r_{\text{tamamlanma}} - p_{\text{boş}} - p_{\text{yakınlık}} - p_{\text{döngü}} - p_{\text{çarpışma}}$$


Ödül yapısının alt bileşenleri ve tetiklenme şartları şu şekilde tanımlanmıştır:

$$\begin{aligned}
r_{\text{zaman}} &= -0.01 \\
r_{\text{keşif}} &= \begin{cases} +3.0 & \text{yeni bir alan Lidar ile görüldüyse} \\ 0 & \text{aksi halde} \end{cases} \\
r_{\text{oda}} &= \begin{cases} +20.0 & \text{yeni bir odaya girildiyse} \\ 0 & \text{aksi halde} \end{cases} \\
r_{\text{tamamlanma}} &= \begin{cases} +60.0 & \text{haritadaki 6 odanın tamamı gezildiyse} \\ 0 & \text{aksi halde} \end{cases} \\
p_{\text{boş}} &= \begin{cases} -0.10 & \text{son 50 adımda hiçbir yeni yer görülmediyse} \\ 0 & \text{aksi halde} \end{cases} \\
p_{\text{yakınlık}} &= \begin{cases} -\left(\frac{0.7 - \min(\text{Lidar})}{0.7}\right) \times 0.3 & \text{eğer } \min(\text{Lidar}) < 0.7 \text{ metre ise} \\ 0 & \text{aksi halde} \end{cases} \\
p_{\text{döngü}} &= \begin{cases} -0.10 & \text{ajan son 60 adımda bulunduğu hücreden tekrar geçerse} \\ 0 & \text{aksi halde} \end{cases} \\
p_{\text{çarpışma}} &= \begin{cases} -40.0 & \text{duvar veya hareketli engele çarpıldıysa} \\ 0 & \text{aksi halde} \end{cases}
\end{aligned}$$

Teorik olarak kurgulanılan bu ödül mekanizmasının pratik başarısı, eğitim eğrilerindeki yakınsama hızı ve modelin kararlılığıyla somutlaşmaktadır.


### 3. Eğitim Süreci ve Grafik Analizi

Eğitim sürecindeki metrikler, sinir ağının çevresel dinamikleri ne ölçüde anlamlandırdığını ve Q-değeri tahminlerindeki isabet oranını göstermektedir.




## Grafik 1 — Öğrenme Eğrisi

1. **Gözlem:** Eğitimin ilk 500 bölümünde ajan sıfıra yakın ortalama ödüller alırken, 500. adımdan itibaren 300 ödül bandına doğru istikrarlı bir yükseliş gözlemlenmektedir.
2. **Karşılaştırma:** Başlangıçtaki kaotik ve yüksek dalgalanmalara kıyasla, eğitimin sonlarına doğru farklı seedler arasındaki performans uçurumları azalarak plato evresine girilmiştir.
3. **Açıklama:** Ajan, epsilon (keşif) değeri düştükçe rastgele hareket etmeyi bırakıp öğrendiği Q-değerlerini sömürmeye başlamış ve eksi puan veren çarpışmalardan kaçınmayı öğrenmiştir.
4. **Sonuç:** Geliştirilen algoritma, stokastik çevre dinamiklerini başarıyla modellemiş ve engellerden kaçınarak odaları gezen optimal bir navigasyon politikası geliştirebilmiştir.




## Grafik 2 — Test (Eval) Eğrisi

1. **Gözlem:** Rastgelelik kapatılarak sömürü (deterministic) modunda çalıştırılan politikanın 20 test bölümü boyunca ortalama 300 ödül civarında seyrettiği görülmektedir.
2. **Karşılaştırma:** Eğitim eğrisinin pürüzsüz yapısına kıyasla, test eğrisinde geniş bir standart sapma bandı (100 ile 600 ödül arası) oluştuğu tespit edilmiştir.
3. **Açıklama:** Bu geniş varyans, ortamın her seferinde farklı bir rastgele konumdan başlamasından kaynaklanmakta olup; ajan dezavantajlı açılarda doğduğunda ezberlediği rota bocalarken, uygun açılarda tüm odaları gezerek maksimum puana ulaşmaktadır.
4. **Sonuç:** Model genel anlamda problemi çözme kapasitesini kanıtlasa da, sıfır keşif oranının (%100 sömürü) zorlu başlangıç konumlarında ajanın genelleştirme yeteneğini ufak çapta kısıtladığı anlaşılmıştır.



**Grafik 3 — Loss (Kayıp) Eğrisi (Özel İstek: Ekstra Paragraf)**


- Gözlem:** DQN ağıının Huber loss (TD hatası) değeri başlangıçta yüksek seviyelerde seyrederken eğitimin ilerleyen adımlarında sıfıra doğru kararlı bir düşüş sergilemiştir.
- Karşılaştırma:** İlk başlardaki ani kayıp sıçramalarına kıyasla, ilerleyen bölümlerdeki loss dalgalanmalarının çok daha dar bir bantta gerçekleştiği görülmektedir.
- Açıklama:** Replay buffer sürekli yeni verilerle dolsa da hedef ağ (target network) güncellemeleri sayesinde stabilite sağlanmış, ağıın Q-değeri tahminlerindeki hata payı minimize edilmiştir.
- Sonuç:** Eğitim stabilitesi başarıyla korunmuş ve modelin gelecekteki ödülleri tahmin etme yeteneği matematiksel olarak yakınsamıştır (converged).



**Grafik 4 — Hiperparametre Duyarlılığı**


- Gözlem:** Öğrenme hızı (learning rate) ve indirim faktörü (gamma) değişikliklerinin, modelin son 50 bölümdeki ortalama episode getirisini doğrudan etkilediği görülmektedir.
- Karşılaştırma:** Düşük gamma değerlerine kıyasla, yüksek gamma değerinin (0.99) ajan performansını belirgin bir şekilde artırdığı ve maksimize ettiği saptanmıştır.

3. **Açıklama:** Gamma değerinin yüksek olması ajanın gelecekteki uzun vadeli ödülleri önemseyerek haritada yeni yerler bulmaya yönelik "**keşif**" (**exploration**) davranışını teşvik etmiş; düşük öğrenme hızları ise mevcut bilgiyi koruyarak stabil bir "**sömürü**" (**exploitation**) imkanı tanımıştır.
4. **Sonuç:** Keşif ve sömürü dengesi, uzak odaları bulmayı ödüllendiren yüksek gamma (0.99) ve stabiliteyi sağlayan düşük öğrenme hızı ( $1e-4$ ) birlikteliği ile en optimal noktaya ulaşmıştır.




**Grafik 5 — Baseline (Rastgele Politika) Karşılaştırması**

1. **Gözlem:** Geliştirilen DQN ajanının performansı, ortamda rastgele yönlere hareket eden bir taban çizgisi (baseline) politikasıyla yan yana karşılaştırılmıştır.
2. **Karşılaştırma:** Rastgele politika ortalama -15 puan seviyelerinde kalarak çakılırken, DQN ajanının 300 puan üzerine çıkarak baseline'ı açık ara farkla geride bıraktığı tespit edilmiştir.
3. **Açıklama:** Çevrenin büyüklüğü, rüzgar gürültüsü ve ağır çarpışma cezaları nedeniyle tesadüfi hareketlerin haritayı çözme ihtimali matematiksel olarak yok denecek kadar azdır.
4. **Sonuç:** Çözülen problemin basit olmadığı, aksine akıllı bir RL algoritmasına kesinlikle ihtiyaç duyulduğu ve DQN'nin bu ihtiyacı üstün başarıyla karşıladığı kanıtlanmıştır.



### Grafik 6 (Epsilon Decay):


1. **Gözlem:** Keşif oranı (epsilon) eğitimin ilk %15'lik kısmında 1.0'dan başlayarak lineer şekilde 0.05'e kadar düşürülmüştür.
2. **Karşılaştırma:** Eğitim başındaki tamamen rastgele uçuş stratejisi ile eğitim sonundaki sömürüye dayalı strateji arasındaki geçişin keskin değil, kademeli olduğu görülmektedir.
3. **Açıklama:** Bu yapılandırma ajanın başlangıçta çevrenin fiziksel sınırlarını özgürce tecrübe etmesine olanak tanımış, epsilon sabitlendiğinde ise haritadaki en kârlı rotalar sömürülmüştür.
4. **Sonuç:** Seçilen %15'lik decay süresi, modelin lokal optimumlara takılmadan haritayı öğrenmesi için yeterli ve ideal bir pencere sunmuştur.



### Grafik 7 (Oda Keşfedilme Süreci):


1. **Gözlem:** Episode başına keşfedilen oda sayısı eğitim ilerledikçe artış göstererek hedef olan 6 oda sınırına güçlü bir şekilde yaklaşmıştır.
2. **Karşılaştırma:** Başlangıçta yalnızca drone'un doğduğu ana oda keşfedilebilirken, ilerleyen bölümlerde ortalama keşif sayısının 4.5 - 5 bandına kadar çıktığı saptanmıştır.
3. **Açıklama:** Çarpışmalardan kaçınmayı öğrenen ajan hayatta kalma süresini uzattığı için doğal bir sonuç olarak haritanın daha derin noktalarındaki odalara erişim imkanı bulmuştur.
4. **Sonuç:** Model sadece havada kalmayı değil, navigasyon görevinin asıl amacı olan alan tarama ve haritalama hedefini de aktif olarak yerine getirmiştir.





**Grafik 8 (Çarpışma Oranı):**

1. **Gözlem:** Tahmini çarpışma oranı eğitimin başlarında %100'e yakınken zamanla ciddi ve kararlı bir düşüş sergilemiştir.
2. **Karşılaştırma:** İlk bölümlerde ajanın hareketleri sıklıkla erken sonlanmaya sebep olurken, eğitim sonunda drone çok daha uzun süre havada kalmayı başarmıştır.
3. **Açıklama:** Lidar sensöründen alınan uzaklık verileri ile negatif çarpışma cezaları arasındaki ilişki ağı tarafından doğru şekilde kurulmuş, tehlikeden kaçış eylemleri (Q-değerleri) ağırlık kazanmıştır.
4. **Sonuç:** Ajan, lidar verilerini kullanarak çevresel engelleri algılama ve çarpışmalardan aktif bir şekilde sakınma becerisini kalıcı olarak edinmiştir.



### Grafik 9 (Per-Seed Karşılaştırması):

1. **Gözlem:** Beş farklı rastgele başlangıç durumu (seed) ile çalıştırılan modellerin her birinin kendine özgü bir öğrenme rotası izlediği görülmektedir.
2. **Karşılaştırma:** Bazı seed'ler (örn. Seed 7) daha hızlı ve pürüzsüz bir yükseliş sergilerken, diğerlerinin daha yavaş ivmelendiği tespit edilmiştir.
3. **Açıklama:** Bu farklılık, başlangıç pozisyonlarının rastgeleliğinden ve sinir ağının ilk ağırlık atamalarının gradyan inişi (gradient descent) sürecini etkilemesinden kaynaklanmaktadır.
4. **Sonuç:** Tüm varyasyonlara rağmen beş farklı seed'in de günün sonunda birbirine oldukça yakın ve başarılı bir performans platosuna ulaşması, algoritmanın sağlamlığını (robustness) kanıtlamaktadır.